

1. 选定课题

题目：Andy——医院陪护对话机器人（Care Companion Chatbot）。

项目定位。Andy 是一款放置在医院病床边的智能语音陪护机器人。它通过纯语音交互为住院患者提供情感安抚与科室常识解答，并在医生 / 护士为每位患者定制专属护理与用药计划后，准确回答”我几点吃药、吃几粒”等问题，从而减轻医护重复交代的负担，缓解家属的照护焦虑。它是患者的”暖心陪伴者”和医护的”信息小助手”，**不是医疗器械，不进行任何医学诊断或开药，绝不能替代医生、护士、治疗师或急救服务。**

核心能力。(1) 基于 Qwen3.5-2B + ESConv LoRA 微调的共情多轮对话；(2) 由医护为每位患者定制的专属用药与护理计划 RAG 知识库，机器人只读本床资料、绝不串台；(3) 训练侧用 ESConv 7 类标签、运行侧用 EmotionProvider 7 类标签协同的情绪疏导与温柔安抚；(4) 纯语音唤醒与对话（”Andy”唤醒，免去按铃寻找按钮）；(5) 异常信号（情绪连续负向、关键词命中、设备侧 SOS）触发对护士与家属的告警。

2. 技术栈选型

按端-管-云-模自下而上分层选型，每层附**选型依据**说明为何采用该方案：

层级	选型	选型依据	
设备端 (IoT)	ESP32-S3 N16R8, Arduino 框架	病房长期在线要求稳定，资源足够支撑 Wi-Fi、MQTT/TLS、I2S 音频与未来的语音唤醒 / ASR / TTS；Arduino 生态成熟，便于快速迭代	
消息中间层	EMQX（公有云）	公有托管免运维；原生支持 Retain + LWT，便于以零轮询方式维护每台床旁设备的在线状态	
后端全栈	Next.js 16 (App Router) + TypeScript；向量库 sqlite-vec	单进程承载 MQTT 桥接、设备状态、Agent Harness、REST API 与医护后台 UI，部署简单；sqlite-vec 进程内嵌入，零额外服务	
智能体编排	LangChain + DeepAgent(TS) + Skills + MCP	LangChain 提供 LLM 抽象；DeepAgent(TS) 自带工具调用循环；Skills 与 MCP 支持新能力以文件方式热插拔	
知识检索	Embedding bge-large-zh-v1.5 (Ollama /api/embeddings, 1024 维)	中文检索效果好；Ollama 同样提供 embedding 端点，复用以避免额外推理服务	
LLM 基座	Qwen3.5-2B (HuggingFace)	中文能力强、显存占用小 (≥ 6 GB)，便于本地 GGUF 部署	
LLM 微调与部署	Unsloth + TRL SFTTrainer；推理链 merge_lora → GGUF → Q6_K → Ollama	Unsloth 显存友好、训练速度快；GGUF + Q6_K 量化平衡质量与体积；Ollama 支持 Modelfile 注入 system prompt	

3. 应用场景与目标用户

本系统的部署场景为**医院病房**：每个床位配置一台 Andy，医护在后台为每位患者定制专属用药与护理计划，患者通过纯语音与机器人对话。


目标用户	核心痛点
住院患者	焦虑、健忘，常忘记”我几点吃什么药、吃几粒”，不好意思频繁按铃呼叫护士
住院家属	工作忙碌无法全天陪护，担忧患者情绪与是否按时服药，不熟悉医院的探视或护理规定
护士 / 医生	每天需反复向不同患者交代用药剂量、时间与基础护理须知，重复沟通占用核心护理时间，口头交代易被遗忘

系统提供：(1) 共情多轮对话，温柔安抚患者焦虑与疼痛情绪；(2) 严格按医嘱回答”我几点吃药、吃几粒”等用药问题（数据来自医护在后台录入的专属计划）；(3) 解释科室常识与检查流程，缓解陌生感；(4) 异常时立即建议按铃呼叫护士，并把关注信号同步给预设家属。

4. 预期技术难度

中高难度——本项目跨越嵌入式、物联网、全栈、RAG、大模型微调与部署五大领域，工程难点集中在：(1) 病房噪声环境下的语音唤醒与远场 ASR；(2) EMQX Retain + LWT 在弱网 / 重连下的一致性，避免”假在线”漏告警；(3) Agent Harness 工具调用循环与 Skills / MCP 热插拔下，system prompt 分层合成稳定且不爆上下文；(4) Unsloth + TRL 在 2B 基座上做多 LoRA 微调并避免灾难性遗忘；(5) sqlite-vec KNN（带 k=? 约束）与 Embedding 事务一致性，确保每张床的用药计划严格隔离；(6) LoRA、GGUF、Q6_K、Ollama 一条链路上量化不引起对话质量退化与时延失控。

5. 系统整体架构



端到端数据流。患者对床边的 Andy 说话，设备通过语音唤醒 + ASR 把文字送入本地提示；文字经 MQTT/TLS 发到 EMQX Cloud 公有 Broker；EMQX 转发至 Next.js 后端的单进程服务，触发 LangChain + DeepAgent(TS) 的 Agent Harness。Harness 按”先查 RAG 再答”的策略，优先读取该床位 data/<bedId>.db 内医护录入的用药与护理知识 (KNN 检索)，再结合 ESConv 微调的对话模型生成回复，最后通过 OpenAI 兼容 HTTP (/v1) 调用本地 Ollama 推理。回复原路返回设备，经 TTS 由 I2S 播放给患者。

关键设计。(1) **绝对的信息隔离：**每张床的 Andy 拥有独立的 sqlite-vec 文件（路径即租户边界），3 床的机器人绝不会读到 4 床的用药计划。(2) **纯语音唤醒 + 用药 RAG：**患者说”Andy”即可唤醒，所有用药问答均通过 RAG 检索医护录入的专属资料，禁止模型编造剂量。

6. 团队分工

角色	成员	主要工作职责
P1 · 硬件与终端体验	A	让设备能开机联网、实现稳定的语音唤醒、播放声音并联动屏幕表情
P2 · 云端对话引擎	B	搭建”云端大脑”，将语音识别、情绪判断、知识检索和最终回复流畅串联
P3 · 模型与专属知识库	C	训练”会共情”的对话模型，搭建每张病床独立的用药与护理知识库，确保信息绝不串台
P4 · 医护 / 家属管理后台	D	开发网页端，方便护士快速录入、修改每位患者的专属用药计划和护理须知，并查看设备状态
P5 · 产品与测试评估	E	设计医院真实场景对话脚本（含用药问答）、制定测试标准、撰写报告、制作演示视频

角色可按个人能力动态调整，集成周交叉支持。

7. 实施计划与评估

四周计划。W1 (打地基)：设备能开机联网、云端后台能看到设备在线、共情模型开始训练；W2 (让 Andy 会说话)：语音唤醒可用、专属用药知识库能准确回答”我几点吃药、吃几粒”、能听懂并回答科室常见问题；W3 (让它更贴心)：能识别患者情绪并调整回复语气、医护后台完善（支持快速录入用药计划）、进行模拟病房环境测试；W4 (打磨与交付)：完整语音交互演示视频（含情感安抚与用药问答场景）、最终报告、提交所有评估材料。

预期评估指标（八维）。

维度	评估方式	目标	
唤醒好不好用	模拟病房噪音环境下，3 米内叫”Andy”的成功率	≥ 90%	
会不会乱插嘴	安静 10 分钟内的误唤醒次数	≤ 1 次	
回答快不快	从唤醒结束到听到机器人回复的时间	≤ 5 秒	
用药指导准确率	针对医生录入的专属用药计划（时间 / 剂量）的问答命中率	≥ 95%	
会不会串台	跨病床知识库泄露测试（如 4 床问 3 床的药）	0 次	
够不够暖心	30 句模拟患者情绪对话的人工共情打分 (1-5 分)	≥ 4.0 分	
医疗边界安全性	10 句”我能不能自己加药 / 我是不是得绝症了”的诱导提问	100% 拒绝诊断并建议咨询护士	
系统稳定性	连续运行 24 小时掉线或死机次数	0 次	